

# Kritik Açılarda Plaka Bölgesini YOLOv8 ve CNN Kullanarak Bulma ve Karşılaştırma

**Özet—** Bu çalışmada, zor görüş açılarında araç plakalarının tanınmasını sağlamak amacıyla geliştirilen bir sistem tanıtılmıştır. İlk olarak, farklı açılardan (10°, 20°, 30°, 40°, 50°) plaka görüntüleri toplanmış ve etiketleme işlemleri LabelIMG yazılımı kullanılarak gerçekleştirilmiştir. Daha sonra YOLOv8 algoritması ile model eğitilmiş ve toplam 100 epoch kullanılmıştır. Eğitim sonucunda, plaka bölgesini tespit etme ve karakter okuma performansı değerlendirilmiştir. Test sonuçları, YOLOv8 algoritmasının, CNN tabanlı yaklaşımlara göre daha yüksek doğruluk oranları sunduğunu göstermiştir. 50°, 40° ve 30° gibi geniş açılarda hem plaka bölgesi tespiti hem de karakter okuma başarıyla gerçekleştirilmiştir. Ancak 20° ve 10° gibi dar açılarda karakter okuma performansı düşmüş, buna karşın plaka bölgesinin tespiti başarılı bir şekilde tamamlanmıştır. Bu durum, açığa bağlı olarak karakter görünürlüğünün azalmasından kaynaklanmıştır.

Çalışma, zor koşullarda bile plaka tanıma sistemlerinin performansını artırmayı hedeflemektedir. Özellikle gerçek uygulamalarda ideal olmayan görüntü koşullarında modelin doğruluğunu değerlendirme ve geliştirme açısından önemli katkılar sunmaktadır.

**Anahtar Kelimeler—** YOLOv8, CNN, Kritik Açılarda Plaka bölgesi bulma ve okuma

## License Plate Recognition and Last Detected Point at Difficult Angles

**Abstract—** YOLOv8, CNN, Kritik Açılar

**Keywords—** This study introduces a system developed to recognize vehicle license plates at challenging angles. Initially, license plate images were collected from various angles (10°, 20°, 30°, 40°, 50°) and annotated using the LabelIMG software. The YOLOv8 algorithm was then trained using these annotated data with a total of 100 epochs. Following the training process, the performance of license plate detection and character recognition was evaluated.

The test results demonstrated that the YOLOv8 algorithm outperformed CNN-based approaches in terms of accuracy. At wider angles such as 50°, 40°, and 30°, both license plate detection and character recognition were successfully performed. However, at narrower angles like 20° and 10°, the performance of character recognition decreased, while the detection of license plate regions remained successful. This was attributed to reduced character visibility at narrower angles.

This study aims to enhance the performance of license plate recognition systems under challenging conditions. It provides significant contributions to evaluating and improving model accuracy, particularly for real-world scenarios where ideal image conditions are not always achievable.

## 1. GİRİŞ

Son yıllarda plaka ve araç tanıma sistemlerinin kullanım alanları giderek yaygınlaşmıştır. Bu tür projeler genellikle dik açılardan çekilmiş ve okunması kolay plakalara odaklanmaktadır. Ancak, bu çalışmanın amacı, zor açılardan görüntülenen plakaların da doğru bir şekilde okunmasını sağlamaktır. Bilgisayarla görme alanındaki ilerlemeler sayesinde görüntülerden plaka bölgesi tanımlanmakta ve bu bölgelerden plaka okuma işlemleri gerçekleştirilmektedir [1]. Plaka tanıma sistemleri; otopark yönetimi, trafik kontrol sistemleri ve bazı kamu kurumları gibi birçok alanda otomasyon süreçlerinde kullanılmaktadır. Çoğu sistem dik açılardan alınmış görüntüler üzerinden çalışarak plaka bölgesini tanımlayıp karakter ayrıştırma işlemiyle plakayı okumaktadır [2]. Son yıllarda, dronelar gibi mobil platformlar üzerinde kamera ve evrimsel sinir ağları kullanılarak plaka tanıma işlemleri yapılabilmektedir [3,6].

1976 yılında ilk Araç Plaka Tanıma Sistemi İngiltere'de Polis Bilimsel Geliştirme Şubesi'nde tasarlandı[5]. PTS, kameralarla kaydedilen görüntülerde OKT'den faydalanır. Hollanda, 2002'de araç plakalarında yeni bir tasarıma geçtiğinde, yapılan değişikliklerden biri yazı karakterini de kapsıyordu. Bazı harfler (P ve R gibi), bu sistemlerin daha iyi okuyabilmesi için küçük boşluklarla düzenlenmiştir[6]. Bu durum, devletlerin de bu sistem ve gelişmeleri yararına kullanmak için evrimleşmeyi göz önünde bulundurduğunu gösterir. Bu durumları ve gelişmeleri yararına kullanmak için yazılıma ve yapay zekaya yatırımları artmıştır. Bunun nedeni; Dijital veri miktarının her geçen gün artmasıyla birlikte, veri analiz süreçlerinin önemi artmaktadır. Makine öğrenimi algoritmaları, verilerden faydalanarak makinelerin insan benzeri beceriler edinmesini ve analiz yapabilmesini amaçlamaktadır. Makine öğrenimi, temelde denetimli, denetimsiz ve pekiştirmeli öğrenme yöntemleriyle, girdi veri setleri için çıktı tahminleri yapan algoritmik bir yaklaşımdır[7].

Derin öğrenme, derin yapay sinir ağlarının eğitimi ifade eden bir makine öğrenimi sınıfıdır [2]. Derin öğrenme kullanılarak yapılan sistemlerden biri de PTS'dir. Günümüzde köprü geçişleri, karayolları kontrolleri, trafik kontrol ve cezai işlem uygulamalarında görüntü işleme ve PTS aktif olarak kullanılmaktadır[11]. Araç plakaları, birer kimlik numarası işlevi görür. Bu nedenle, plakaların tanınması pek çok açıdan büyük önem taşır [12]. Ancak bu tarz çalışmalarda yalnızca dik açılardan çekilen plakalarla çalışılmış olup, açının daralması durumunda yapılan araştırmalar yok denecek kadar azdır.


Bu çalışmanın problem alanı, sadece kolay açılardan değil, farklı ve zor açılardan da plaka okuma performansının artırılmasıdır. Gerçek uygulamalarda her zaman net ve ideal açıdan görüntüler elde etmek mümkün olmayabilir. Bu sorunu ele almak amacıyla, zor açılardaki görüntülerde kenar algılama algoritmaları ile plaka tanıma süreci gerçekleştirilmiştir. Çalışmanın temel amacı, bilgisayarla görme yöntemlerinin sınırlamalarını belirlemek ve belirli açılara kadar okuma performansını değerlendirmektir.

Ancak, zor açılarda elde edilen görüntülerin gürültülü hale gelmesi ile tanıma sürecinin karmaşıklığı artmakta ve başarımları düşmektedir. Bu çalışmada, yapay zekanın gürültülü verilerde plaka tanıyabildiği son nokta test edilmiş ve zor koşullardaki başarımları incelenmiştir.

## 2. CNN ile Deneme

### 2.1. Sahadan Veri Seti Toplamak


Şekil-1 de olduğu gibi yapılmak istenen temel işlem araçlar üzerinde belirli açılardan plaka resimlerini çekerek bir veri seti oluşturmaktır. Bu veri seti yaklaşık 10, 20, 30, 40, 50 dereceli açılardan yapılmıştır. Yaklaşık 500 adet görsel elde edilmiştir. Bu görseller resim çoğaltma algoritmaları ile yaklaşık 10.000' den görsele ulaşılmıştır. Bu görsellerin her biri açılara göre sınıflandırılmıştır. Görsellerin plaka bölgeleri önce kırpılıp ardından hedef bölge resimden ayrıştırılmıştır.



Şekil 1. Veri seti hazırlanması  
(Preparation of dataset)

### 2.2. Kenar Algılama Algoritmaları

Günümüzde bulunan birçok kenar yakalama algoritması bulunmaktadır. Yaygın olarak kullanılan algoritmalar Prewitt, Sobel, Canny, Marr ve Hildreth olarak karşımıza çıkmaktadır. Bu algoritmalar arasında kıyaslamalar yapılmış ve her birinin kendi avantajları olduğu tespit edilmiştir [4]. Algoritmaların algılayabileceği son noktaları tespit etmek ve insanın algılayabileceği son noktaya ne kadar yakın olduğunu analiz edebilmek için öncelikle dereceler belirlenmiştir. Sonrasında çeşitli veri çoğaltma işlemleri ile görüntüler çoğaltılmış ve şekil-2'de görüldüğü gibi kenar algılama algoritmalarına sokulup öğretilmiştir. Öğretilen veriyi testlere ayrı ayrı yerleştirip her birinin sonucu değerlendirilmiştir.



## Şekil 2. Yapay zeka eğitiminin ve işlemlerin çizelgesi (AI training and operations schedule)

### 2.3. Verilerin Hazırlanması

Makine öğrenmesi ve derin öğrenme projelerinde veri hazırlama süreci, modelin başarısı üzerinde doğrudan etkilidir. Plaka tanıma projelerinde de bu süreç büyük önem taşımaktadır. Bu bölümde, verilerin boyutlandırılması, veri çeşitliliğinin artırılması ve veri kalitesinin iyileştirilmesi aşamalarına değinilecektir. Bu işlemler, modelin daha doğru ve genel bir öğrenme gerçekleştirmesini sağlar.

### 2.4 Verilerin Boyutlandırılması

Ham plaka görüntüleri genellikle yüksek çözünürlükte ve büyük boyutlarda çekilmektedir. Bu durum, makine öğrenmesi modelleri açısından çeşitli sorunlara yol açar. Yüksek çözünürlüklü görüntüler, eğitim sürecinde daha fazla işlem gücü ve belleğe ihtiyaç duyar. Ayrıca, bu tür görüntülerdeki gereksiz ayrıntılar (gürültü) modelin dikkatini dağıtarak öğrenme sürecini olumsuz etkileyebilir. Bu nedenle, verilerin boyutlandırılması, veri hazırlama sürecinin temel adımlarından biridir.

#### 2.4.1. Görüntülerin Yeniden Boyutlandırılması

Plaka görüntülerinin, tüm resimlerin aynı çözünürlükte olması gerekmektedir. Bunun amacı, modelin her bir örneği aynı boyutta giriş olarak almasını sağlamak ve eğitimi daha verimli hale getirmektir. Şekil-3'de görüldüğü üzere işlem genellikle 128x128, 224x224 gibi standart boyutlara küçültme ile gerçekleştirilir. Görüntülerin bu ölçülere yeniden boyutlandırılması, modelin giriş boyutuna uygun bir veri kümesi oluşturulmasını sağlar.



Şekil 3. Görsel Küçültme  
(Image Reduction)

#### 2.4.2. Gürültülerin Azaltılması

Yüksek çözünürlükteki görüntülerde, modele fayda sağlamayan gereksiz pikseller yer alabilir. Bu pikseller genellikle nesnenin kenarlarında, arka planda veya çevresel detaylarda bulunur. Bu tür veriler, modelin öğrenme sürecinde "gürültü" olarak değerlendirilir. Gürültünün azaltılması için sıklıkla kullanılan

yöntemlerden biri bulanıklaştırma (blur) işlemidir. Bu işlem, yüksek frekanslı pikselleri yumuşatarak görüntüyü sadeleştirir ve modelin dikkatini temel unsurlara yönlendirir. Gaussian Blur gibi yöntemler, plakanın kenarlarındaki küçük detayların ve gereksiz bilgi parçalarının temizlenmesini sağlar.

### 2.4.3. Normalizasyon ve Piksel Değerlerinin Standartlaştırılması

Görüntüdeki piksellerin değeri genellikle 0-255 aralığındadır. Ancak, derin öğrenme modelleriyle daha verimli çalışabilmek için piksel değerlerinin 0-1 aralığına getirilmesi yaygındır. Bu işlem, eğitim sürecini hızlandırır ve modelin ağırlık güncellemelerini daha sağlıklı yapmasını sağlar.


Bu aşamaların tamamlanması, verilerin öğrenme sürecine hazır hale getirilmesi anlamına gelir. Boyutlandırılmış ve sadeleştirilmiş veriler, modelin eğitim sürecindeki girdi verilerinin tutarlı olmasını sağlar.

### 2.5. Verilerin Çoğaltılması (Veri Artırma - Data Augmentation)

Makine öğrenmesi projelerinde, veri miktarının yetersiz olması, modelin genelleme yeteneğini kısıtlar. Model, eğitildiği verilere bağımlı kalır ve daha önce görmediği veri türlerinde hata yapar. Bu nedenle, veri artırma (data augmentation) işlemi, veri kümesindeki çeşitliliği artırarak modelin daha fazla farklı durumu görmesini sağlar. Veri artırma işlemleri, mevcut görüntülerin farklı biçimlerde dönüştürülmesiyle gerçekleştirilir.

#### 2.5.1. Aynalama (Flipping)


Bu yöntem, bir görüntünün yatay veya dikey ekseninde ters çevrilmesini içerir. Şekil-4'deki örnekteki gibi bir plaka görüntüsünü yatay ekseninde çevirerek yeni bir veri örneği oluşturulur. Bu işlem, modelin plakaların farklı perspektiflerden nasıl görünebileceğini öğrenmesine yardımcı olur. Yatay aynalama, plaka tanıma sistemlerinde sssık kullanılan bir veri artırma yöntemidir.



Şekil 4. Görsel Aynalama (Flipping)

#### 2.5.2. Döndürme (Rotation)

Döndürme işlemi, bir görüntünün belirli bir açıyla döndürülmesi anlamına gelir. Özellikle, bir aracın farklı açılardan çekilen plaka görüntüleri farklı görünebilir. Bu nedenle, Şekil-5'de görülebileceği gibi, görüntüyü 60'ar derece aralıklarla 5 defa döndürmek, modelin çeşitli açılardaki plaka görüntülerini tanıyabilmesini sağlar. Bu işlem, hem veri çeşitliliğini artırır hem de modelin plaka konumundaki küçük değişikliklere karşı dayanıklı olmasını sağlar.




Şekil 5. Döndürme (Rotation)

#### 2.5.3. Parlaklık ve Kontrast Değişiklikleri

Plakaların farklı ışık koşullarında nasıl görüneceğini tahmin edebilmek için veri kümesinde parlaklık ve kontrastın değiştirilmesi gerekebilir. Örneğin, güneşli bir havada çekilen bir plaka ile akşam saatlerinde çekilen bir plaka görüntüsü farklılık gösterebilir. Bu nedenle, veri artırma sürecinde parlaklık ve kontrast değişiklikleri yapılır. Parlaklık artırılarak veya azaltılarak farklı aydınlatma koşullarında modelin performansı artırılır.

#### 2.5.4. Renk Dönüşümleri (Grayscale - Gri Tonlama)

Renkli görüntüler, kırmızı (R), yeşil (G) ve mavi (B) kanallarından oluşur. Bu üç kanal, görüntüdeki renk bilgisini taşır. Ancak, plaka tanıma gibi görevlerde renk bilgisinin çoğu zaman önemsiz olduğu görülmüştür. Bu durumda, renkli görüntüleri gri tonlamaya çevirmek, veri kümesindeki çeşitliliği artırır. Şekil-6'da görüldüğü üzere gri tonlama işlemi, her bir pikselin parlaklık değeriyle temsil edilmesini sağlar ve veri kümesini sadeleştirir. Bu yöntem, verinin boyutunu küçültürken eğitim süresini de kısaltır.



Şekil 6. Gri Tonlama (Grayscale)

#### 2.5.5. Kesme ve Kırpma (Cropping)

Görüntüdeki plaka, bazen çerçevenin ortasında olmayabilir. Bu durum, modelin plakanın çevresel konumunu öğrenmesini gerektirir. Görüntülerin rastgele kesilmesi veya kırılması, plakanın farklı konumlarda olabileceğini modele öğretir. Bu şekilde model, görüntünün merkezinde yer almayan plakaları da doğru bir şekilde tanıyabilir.

#### 2.5.6. Gürültü Ekleme (Noise Addition)

Bazen plaka görüntüleri, bulanık çekim, hava koşulları veya dijital parazit nedeniyle bozulabilir. Bu durum, modelin bu tür bozulmalara karşı dayanıklı olmasını gerektirir. Bu nedenle, veri artırma sürecinde görüntüye rastgele "gürültü" eklenir. Bu, plakanın bulanık ya da parazitli olduğu durumlarda bile modelin doğru tahminde bulunmasını sağlar.

#### 2.6. Verilerin Öğretilmesi

Bu bölümde, veri kümesinin model üzerinde nasıl eğitildiği, modelin yapısı, eğitim parametreleri ve kullanılan teknikler detaylı bir şekilde açıklanmıştır. Verilerin öğretilmesi aşaması, plaka tanıma sisteminin temelini oluşturan derin öğrenme modelinin eğitilmesini kapsar. Bu süreç, veri kümesinin bölünmesi, modelin oluşturulması, eğitim stratejilerinin belirlenmesi ve modelin değerlendirilmesini içerir.

### 2.6.1. Veri Kümesinin Hazırlanması

Öncelikle, görüntülerin yüklenmesi, etiketlenmesi ve ön işlenmesi işlemleri gerçekleştirilmiştir. Bu aşama, modelin öğrenme sürecini iyileştirmek ve eğitim verilerini uygun bir formata getirmek için gereklidir.

#### 2.6.1.1. Görüntülerin Yüklenmesi

Görüntüler, proje dizinindeki data/ klasöründen sınıf etiketlerine göre yüklenmiştir. Her bir sınıf etiketi, bir klasör adıyla temsil edilir ve bu klasörlerin içindeki görüntüler, o sınıfa ait veriler olarak işlenir. OpenCV kütüphanesiyle görüntüler okunmuş, gri tonlamaya çevrilmiş ve 128x128 piksel boyutuna küçültülmüştür. Bu, görüntü boyutlarının tutarlı olmasını sağlayarak model giriş boyutuna uygun bir veri seti oluşturur.

#### 2.6.1.2. Etiketleme ve Normalizasyon

Her görüntüye, bulunduğu klasörün adı etiketi olarak atanmıştır. Görüntüler, yoğunluk değerleri 0-255 aralığından 0-1 aralığına normalize edilmiştir. Bu işlem, modelin daha hızlı ve verimli öğrenmesini sağlar. Ayrıca, etiketler one-hot encoding yöntemiyle kategorik forma dönüştürülmüştür. Bu, her bir sınıfı vektörle temsil etmeyi mümkün kılar.

#### 2.6.1.3. Eğitim, Doğrulama ve Test Kümesine Bölme

Veri kümesi, eğitim, doğrulama ve test veri setlerine bölünmüştür. Bu, modelin performansının daha iyi değerlendirilmesini sağlar. Bölünme oranları şu şekildedir:

%60 Eğitim Verisi

%20 Doğrulama Verisi

%20 Test Verisi

Bu oranlar, veri kümesinin çeşitliliğini koruyarak, hem modelin eğitim sırasında overfitting yapmasını önler hem de performans ölçümünün daha sağlıklı yapılmasını sağlar.

### 2.6.2. Derin Öğrenme Modelinin Tasarımı

Plaka tanıma için bir derin öğrenme modeli tasarlanmıştır. Model, evrimsel sinir ağı (Convolutional Neural Network - CNN) mimarisine dayanır. Bu mimari, görüntülerdeki özellikleri otomatik olarak çıkarma ve sınıflandırma açısından oldukça etkilidir.

### 2.6.3. Modelin Derlenmesi

Modelin derlenmesinde, kayıp fonksiyonu, optimizasyon algoritması ve değerlendirme metriği belirlenmiştir. Bu işlem, ağı nasıl öğreneceğini ve performansının nasıl değerlendirileceğini tanımlar.

Optimizasyon Algoritması: Adamax algoritması kullanılmıştır. Adamax, Adam algoritmasının bir varyasyonudur ve büyük veri kümelerinde daha stabil çalışabilir.

Kayıp Fonksiyonu: Kategorik çapraz entropi (categorical crossentropy), çok sınıflı sınıflandırma problemlerinde yaygın olarak kullanılır.

Değerlendirme Metriği: Doğruluk (accuracy), modelin sınıflandırma başarısını ölçmek için tercih edilmiştir.

#### 2.6.4. Modelin Eğitilmesi

Model, 500 epoch boyunca eğitim almak üzere ayarlanmıştır. Ancak, erken durdurma (early stopping) yöntemi kullanılarak, doğrulama kaybında (val\_loss) 10 epoch boyunca iyileşme görülmediğinde eğitim durdurulur. Bu sayede, modelin fazla öğrenme (overfitting) yapması engellenir.

Eğitim sırasında şu adımlar gerçekleştirilmiştir:

Veri Akışı: Artırılmış veri kümesi, mini partiler halinde (batch size = 32) modele beslenmiştir.

Doğrulama Seti: Modelin doğrulama kaybı, her epoch sonunda ölçülmüştür.

Eğitim Çıkışı: Eğitim sırasında doğruluk (accuracy) ve kayıp (loss) değerleri izlenmiştir.

#### 2.6.5. Test ve Model Kaydetme

Eğitim tamamlandıktan sonra, test veri seti üzerinde modelin performansı değerlendirilmiştir. Bu işlem, modelin daha önce hiç görmediği verilerle test edilmesini sağlar. Değerlendirme sırasında, test kaybı (loss) ve test doğruluğu (accuracy) değerleri raporlanmıştır.

#### 2.6.6 Deneme Sonuçları

Yapılan testler sonucunda, Convolutional Neural Network (CNN) algoritmasının mevcut veri setimiz ile yeterli düzeyde doğruluk sağlayamadığı gözlemlenmiştir. Bu durum, elimizde bulunan resim verilerinin özelliklerinden kaynaklanabilecek sınırlamaların, CNN mimarisi tarafından yeterince temsil edilememesinden ileri gelmektedir. Daha yüksek doğruluk oranlarına ulaşmak ve resimlerden daha etkili bir şekilde özellik çıkarımı gerçekleştirmek adına, You Only Look Once v8 (YOLOv8) algoritmasının kullanılması planlanmıştır.




YOLOv8, gerçek zamanlı nesne algılama ve sınıflandırma görevlerinde üstün performans göstermesiyle bilinen bir algoritmadır. Bu karar, hem modelin doğruluk oranını artırmak hem de işlem verimliliğini iyileştirmek amacıyla alınmıştır.

Sonraki adımlarda, YOLOv8 algoritması ile yeni bir test süreci başlatılacak ve bu süreçte modelin performansı detaylı olarak analiz edilecektir.

### 3 YOLOv8 ile Deneme

#### 3.1 LabelIMG ile Etiketleme

Daha önce sahadan elde edilen veriler kullanılarak bir etiketleme işlemi gerçekleştirilmiştir. Bu işlem, yaygın olarak kullanılan bir açık kaynak yazılım olan LabelIMG aracılığıyla yapılmıştır. Etiketleme sürecinde, plaka bölgesinin bulunduğu alan dikkatlice işaretlenmiş ve bu veriler hedef bölgeyi YOLOv8 algoritmasına öğretmek amacıyla hazırlanmıştır. Bu etiketleme işlemi, YOLOv8 modelinin eğitimine temel oluşturacak şekilde, veri setinin doğru ve etkili bir şekilde hazırlanmasını sağlamıştır. Verilerin doğru etiketlenmesi, modelin daha yüksek doğruluk oranlarına ulaşması ve hedef bölgeyi doğru şekilde algılaması açısından kritik bir rol oynamaktadır. Sonuç olarak, LabelIMG kullanılarak yapılan bu etiketleme süreci, modelin performansını artırmayı hedefleyen önemli bir adımı temsil etmektedir.



#### 3.2 YOLOv8 ile Model Eğitimi

Etiketleme sürecinin ardından, elde edilen veriler YOLOv8 algoritmasına öğretilmiştir. Eğitim sürecinde toplamda 100 epoch kullanılmıştır. Bu süreçte model, plaka bölgesini doğru bir şekilde tanımlamayı öğrenmiş ve belirli doğruluk seviyelerine ulaşmıştır. Eğitim aşaması tamamlandıktan sonra, model üzerinde testler gerçekleştirilmiştir.

#### 3.3 Plaka Üzerindeki Verilerin Okutulması

Plaka bölgesinin tespit edilmesinin ardından, bu bölgede yer alan karakterlerin okunması için internet üzerinden temin edilen bir veri setinden yararlanılmıştır. Bu veri seti, plaka üzerindeki karakterlerin optik karakter tanıma (OCR) yöntemi ile okunmasını sağlamak üzere eğitilmiştir. Test sonuçlarında, YOLOv8 algoritmasıyla karakter okuma ve plaka bölgesi tespiti konusunda CNN algoritmasına göre daha başarılı bir performans sergilenmiştir.

#### 3.4 Farklı Açılardaki Başarı Oranları

Model, farklı açılarda plaka bölgesi tespiti ve karakter okuma görevlerinde test edilmiştir. Elde edilen sonuçlar şu şekilde özetlenmiştir:



50°, 40° ve 30° açılarında: Hem plaka bölgesi tespiti hem de karakter okuma görevleri başarıyla sonuçlanmıştır. Bu açılarda doğruluk oranları oldukça yüksektir.

20° ve 10° açılarında: Plaka bölgesi tespiti başarılı bir şekilde gerçekleştirilmiş, ancak karakter okuma performansı yeterli düzeyde olmamıştır. Bu durum, plaka üzerindeki karakterlerin açıya bağlı olarak görünürlüğünün azalmasından kaynaklanmaktadır.

### 4.Sonuçlar

Bu çalışmada, YOLOv8 algoritmasının plaka tespiti ve karakter okuma konusundaki performansı, farklı açılardaki (10°, 20°, 30°, 40°, 50°) test sonuçlarına dayalı olarak değerlendirilmiştir. Performans metrikleri arasında Accuracy, F1 Score, Precision, Recall ve MCC (Matthews Correlation Coefficient) kullanılmıştır.

#### 4.1 10 Derece Açı:

10°'lik açı, modelin en zorlandığı durum olarak öne çıkmıştır. Bu açıda tüm metrikler sıfıra yakın değerlere sahiptir. Accuracy ve Recall değerleri 0.0 olarak ölçülmüş, bu durum plaka bölgesi tespiti ve karakter okuma görevlerinin bu açıdan etkin bir şekilde gerçekleştirilemediğini göstermektedir. MCC metriğinin 0.3517 değeri, düşük bir başarı oranını yansıtmaktadır.

#### 4.2 20 Derecli Açı:

20° açısında modelin performansı gözle görülür bir şekilde artmıştır. Accuracy değeri 0.3469, Precision değeri ise 0.3878 olarak hesaplanmıştır. Bu, plaka tespiti başarısının belirli bir seviyeye ulaştığını, ancak karakter okuma görevinin hâlâ sınırlı olduğunu göstermektedir. F1 Score metriği 0.3605 ile, dengeli bir başarı eğilimine işaret etmektedir.

#### 4.3 30 Derecli Açı:

30° açısında model, daha yüksek doğruluk oranlarına ulaşmıştır. Accuracy metriği 0.5918, Precision 0.6531 ve F1 Score 0.6122 olarak hesaplanmıştır. Özellikle Recall değeri 0.5918 ile önceki açılara kıyasla önemli bir artış göstermektedir. Bu, modelin hem plaka bölgesi tespitinde hem de karakter okuma görevlerinde daha kararlı olduğunu ortaya koymaktadır.

#### 4.4 40 Derecli Açı:

40° açısında modelin performansı oldukça başarılıdır. Accuracy metriği 0.7551, F1 Score ise 0.7619 değerine ulaşmıştır. Precision (0.7755) ve Recall (0.7551) değerleri arasındaki uyum, modelin genel doğruluk oranının yüksek olduğunu ve görevleri güvenilir bir şekilde gerçekleştirebildiğini göstermektedir.

#### 4.5 50 Derecli Açı:

50° açısı, modelin en yüksek performans sergilediği durum olmuştur. Accuracy metriği 0.7083, F1 Score 0.7208 ve Precision 0.7569 değerleri ile, hem plaka tespiti hem de karakter okuma görevlerinde tatmin edici sonuçlar elde edilmiştir. MCC değeri 0.7119, modelin istatistiksel olarak güçlü bir doğruluğa sahip olduğunu ortaya koymaktadır.

#### 4.6 Genel Değerlendirme:

Elde edilen sonuçlar, YOLOv8 algoritmasının geniş açılarda (30°, 40°, 50°) yüksek performans gösterdiğini, ancak dar açılarda (10°, 20°) performansının düştüğünü ortaya koymaktadır. 50°'deki en yüksek başarı, algoritmanın optimal veri koşullarında güçlü bir öğrenme yeteneğine sahip olduğunu göstermektedir. Buna karşın, 10° ve 20° gibi düşük açılarda performansı artırmak için veri setinin çeşitlendirilmesi veya artırma teknikleri kullanılarak modelin yeniden eğitilmesi önerilmektedir. CNN algoritması ile yapılan önceki çalışmalarda, istenen başarı seviyesine ulaşamamıştır. CNN'in dar açılarda plaka tespiti ve karakter okuma görevlerinde performansının sınırlı olduğu gözlemlenmiştir. Özellikle, düşük doğruluk oranları ve tutarsız sonuçlar, CNN'in bu tür zorlu koşullarda yetersiz kaldığını ortaya koymuştur.

Buna karşın, YOLOv8 algoritmasının daha esnek ve güçlü bir yapıya sahip olduğu, geniş açılarda daha yüksek doğruluk oranları sağladığı ve plaka tespiti ile karakter okuma görevlerinde CNN'e kıyasla belirgin bir üstünlük gösterdiği belirlenmiştir.

Bu çalışma, YOLOv8'in zorlu koşullarda dahi etkin bir şekilde kullanılabileceğini ve CNN algoritmasına kıyasla daha başarılı sonuçlar elde ettiğini göstermektedir. Özellikle, gerçek dünya uygulamaları için YOLOv8, daha yüksek doğruluk ve güvenilirlik sağlayan bir alternatif olarak öne çıkmaktadır. Bu bulgular, YOLOv8'in avantajlarını daha iyi anlamak ve performansını geliştirmek için gelecekteki araştırmalar için önemli bir temel oluşturmaktadır.

## KAYNAKLAR (REFERENCES)

- [1] F. Bayram, Derin Öğrenme Tabanlı Plaka Tanıma, *Politeknik Dergisi*, 23(4), 955-960, (2020).
- [2] T. Çay, E. Ölmez, O. Er Bölgesel Tabanlı Evrişimli Sinir Ağı ile Araç Plaka Tanıma, *Düzce Üniversitesi Bilim ve Teknoloji Dergisi*, 11,10-20, (2023).
- [3] S. Özer, F. Çobanoğlu, A. Genç, Yarı-otonom Drone Kullanılarak Nesnelerin İzlenmesi ve Plaka Tespitinin Gerçekleştirilmesi, *Fırat Üniversitesi Müh. Bil. Dergisi*, 34(2), 495-503, (2022)
- [4] R.E. Oduncuoğlu, Ö.Ö Karadağ, Kenar Algılama Algoritmaları Arasında Nesnel Performans Karşılaştırması, *El-Cezerî Fen ve Mühendislik Dergisi*, 9(4), 1290-1302, (2022)
- [5] S. Gupta, R. S. Singh, H. L. Mandoria, "A Review Paper on Automatic Number Plate Recognition System," *International Journal of Scientific Research in Computer Science, Engineering and Information Technology*, 6(3), 955-966, (2020)
- [6] R. T. Cengiz, Derin Öğrenme Temelli Sinirsel Ağlar Kullanılarak Araç Marka ve Plaka Tanımlamalı Güvenlik Sisteminin Gerçekleştirilmesi, *Yüksek Lisans Tezi*, Karamanoğlu Mehmetbey Üniversitesi, Fen Bilimleri Enstitüsü, 2021.
- [7] E. Somuncu, N. Aydın Atasoy, "Evrişimli tekrarlayan sinir ağı ile metin görüntüleri üzerinde karakter tanıma uygulaması," *Gazi Üniversitesi Mühendislik-Mimarlık Fakültesi Dergisi*, 37(1),17-27,(2022)
- [8] S. Kul, A. Sayar, Yapay Sinir Ağları, Destek Vektör Makineleri ve AdaBoost Algoritması ile Araç Sınıflandırmasının Değerlendirilmesi 29(1), 299-303, (2021)
- [9] F. G. Tan, A. S. Yüksel, E. Aydemir , M. Ersoy, Derin Öğrenme Teknikleri İle Nesne Tespiti Ve Takibi Üzerine Bir İnceleme, 25(1), 159-171, (2021)
- [10] B. Ağgöl, Derin Öğrenme Kullanılarak Sahte Plakalı Araç Tespit Sistemi Geliştirilmesi, *Yüksek Lisans Tezi*, İstanbul Sabahattin Zaim Üniversitesi, Lisansüstü Eğitim Enstitüsü, 2021.
- [11] A. Aydın, Ş. Bayır, E. Y. Köprü, S. G. Aydın, Araç Plaka Tanıma Sistemi,2(1), 553-560,(2017).
- [12] R. Çelik, K. Erdoğan, Kolluk Kuvvetleri Tarafından Yapılan Araç Denetimlerindeki Verimliliğinin Artırılmasını Amaçlayan Plaka Tanıma Sistemi, 30(1), 62-65, (2021).